

Data Mining & Analytics

Utvalg, distribusjoner, sannsynlighet og korrelasjoner

Lynkurs i statistikk og forskningsmetode


Samling 2, dag 1

Agenda

- Del 1: Utvalg, distribusjoner og sannsynlighet
- Del 2: Korrelasjon
- Del 3: Forskningsmetode og statistiske tester
- Kodeeksempler til hvert tema legges ut på GitHub - vi veksler mellom slides og jupyter notebook

Plan for dagen

Tid	Undervisningsform
08:30 – 09:00	Forelesning
09:15 – 11:45	Øvningsoppgaver
11:45 – 12:15	Lunsj
12:15 – 12:45	Forelesning
13:00 – 15:00	Øvningsoppgaver
15:00 – 15:30	Oppsummering



Del 1: Utvalg, distribusjoner og sannsynlighet


Hvorfor bør vi kunne litt statistikk?

For å:

- Finne ut hvilke data vi bør samle inn
- Beskrive/oppsummere data vi har samlet inn
- Teste hypoteser – hva er best av alternativ A eller B?
- Gjøre prediksjoner

«Frekventist» eller «probabilist»

- Frekventister
 - Bruker den relative frekvensen, i et utvalg med mange observasjoner, til å angi sannsynlighet
 - Bruker data fra et utvalg til å estimere parametere for den totale den populasjonen (med konfidensintervall)
- Probabilister (Bayesisk sannsynlighetregning)
 - Starter med et subjektivt sannsynlighetsestimat og oppdaterer estimatet basert på nye observasjoner




Data

- Talldata
 - Kontinuerlig
 - Diskrete
- Kategoriske
 - Binære
 - Nominale
 - Ordinale

Populasjon vs. utvalg

- Populasjon: Den fulle distribusjonen vi egentlig er interessert i å si noe om
- Utvalg: en delmengde som vi faktisk måler
- Parametere (μ , σ) beskriver faktisk gjennomsnitt og std.avvik i populasjonen. Vil alltid være det samme så lenge ikke populasjonen endres
- De statistiske målene ($\bar{x}$, s) beskriver gjennomsnitt og std.avvik for utvalget. Disse varierer fra utvalg til utvalg






Utvalgsmetoder

- De mest elementære
 - Enkelt tilfeldig utvalg: alle har lik sjanse for å bli trukket
 - Stratifisert utvalg: trekke proporsjonalt fra kjente undergrupper (kjønn, aldersgrupper, etc)


Utvalgsfordeling og standardfeil

- Trekk mange utvalg $\rightarrow$ fordelingen av $\bar{x}$ kalles utvalgsfordelingen
- Standardfeil: $SE = \frac{\sigma}{\sqrt{n}}$, SE krymper med kvadratroten av n
- For å halvere usikkerheten må n firedobles



Normalfordelingen

- Kjennetegnes av en symmetrisk klokkeform
- 68 % av dataene ligger innenfor $\pm \sigma$, 95 % innenfor $\pm 2\sigma$, 99,7 % innenfor $\pm 3\sigma$




Er dataene normalfordelte?

- Shapiro–Wilk: H_0 = «dataene er normalfordelte»
 - Er $p > 0.05$ så beholder man H_0 -hypotesen – dataene er normalfordelte
 - Er $p < 0.05$ så forkaster man H_0 -hypotesen og går for den alternative hypotesen – dataene er ikke normalfordelte
- Sjekk med histogram + QQ-plott

Del 2: Korrelasjon


Pearson korrelasjon (r)

- Måler lineær samvariasjon mellom to variabler
- $r \in [-1,1]$
- R^2 = andel av variansen i y forklart lineært av x




Anscombes kvartett

- 4 datasett med nesten identisk gjennomsnitt, varians, r og regresjonslinje
- Helt ulik struktur: lineær, kurve, uteligger, ekstremverdi
- Tips/konklusjon: se alltid på scatterplottet, ikke bare tallet



Korrelasjon $\neq$ kausalitet

- Konfunderende variabel: temperatur $\rightarrow$ både iskrem og drukning
- Partiell korrelasjon (kontrollert for temp) ≈ 0
- Simpsons paradoks: sammenheng kan snu når data grupperes
- Sjekk alltid (forsøk å finn ut) om det finnes en tredje variabel som styrer begge




Del 3: Forskningsmetode og statistiske tester

Hypotesetesting

- Eksempel: trener 1x/uke vs. 3x/uke – hvem løper lengst etter 12 uker?
- H_0 (nullhypotesen): ingen forskjell mellom gruppene
- H_a (alternativhypotesen): gruppe 2 løper lenger
- Statistisk test $\rightarrow$ p-verdi $\rightarrow$ konklusjon

Hva betyr egentlig en p-verdi?

- p = sannsynligheten for å observere noe mer «ekstremt» enn det man allerede har observert når H_0 er sann
- $p < 0,05$ er en konvensjon, ikke en naturlov




Effektstørrelse: Cohens d

- p-verdien sier om det er en forskjell mellom gruppene, men ikke hvor stor
- Cohens d ($d = (\bar{x}_1 - \bar{x}_2) / s_p$) gir forskjell i antall standardavvik
- Tommelfingerregel: 0,2 liten · 0,5 middels · 0,8 stor
- Rapporter alltid konfidensintervall og ikke bare p
 - Gjerne effektstørrelse også

Styrke (power) og utvalgsstørrelse

- Type I-feil (α): forkaster sann H_0 (falsk positiv)
- Type II-feil (β): beholder usann H_0 (falsk negativ)
- Power = $1 - \beta$: sannsynligheten for å oppdage en reell effekt
- Avhenger av effektstørrelse, n , varians og α



Velge riktig test


Sammenligning	Parametrisk	Ikke-parametrisk
2 uavhengige grupper	Welch t-test	Mann–Whitney U test
2 parvise målinger	Paret t-test	Wilcoxon signed-rank test
To kategoriske variabler	Kjikkvadrattest	Fisher-test

P-hacking

- Å teste mange subgrupper til man finner noe «signifikant»
- 12 tilfeldige subgrupper på ren støy fører ofte til minst 1 eller flere «signifikante» funn
- Definer hypotese og analyseplan **før** dere ser på dataene
- Rapporter alle tester dere gjorde og ikke bare de som «virket» ($p < 0.05$)

Sammenligning av ML-modeller

- Repetert k-fold gir mange skårer, men de er ikke uavhengige
- Foldene deler treningsdata → naiv t-test er for optimistisk
- Nadeau–Bengios korrigerte t-test justerer variansen for dette
- Rapporter differanse og konfidensintervall, ikke bare $p < 0,05$



Takk for i dag!

I morgen: regresjon og klassifisering