


Maskinlæring

Regresjon og klassifisering – Samling
2, dag 2

Agenda

- Del 1: Regresjon
- Del 2: Klassifisering
- Kryssvalidering, modellsammenligning og hyperparametersøk går igjen for både regresjon og klassifisering

Typer maskinlæring




Del 1: Regresjon

Notasjon


- X : input-data
- y : «target» / det vi vil predikere
- $f(X)$: modellen
- $\hat{y}$: prediksjonen
- $L(\hat{y}, y)$: tapsfunksjonen

Ordinary Least Squares (OLS)

- Minimerer summen av kvadrerte residualer: $\sum (y_i - \hat{y}_i)^2$
- Finne optimale beta-verdier
 - $\hat{y} = \beta_0 + \beta_1 x_1$
- $\hat{\beta} = (X^T X)^{-1} X^T Y$
- Fungerer for lineær og polynomregresjon (samme metode, flere features)



Linær regresjon



Metrikker for regresjon


Metrikk	Formel	Egenskap
MAE	$\frac{1}{n} \sum_{i=1}^n (y - \hat{y})$	samme enhet som y
MSE / RMSE	$\frac{1}{n} \sum_{i=1}^n (y - \hat{y})^2$	straffer store feil mer enn mindre feil
RMSE	$\sqrt{MSE}$	Samme som MSE, men gir svaret i samme enhet som variabelen vi predikerer
R ²	$1 - \frac{SS_{res}}{SS_{Tot}}$	Hvor mye av variansen i dataene er forklart av modellen 0=som å gjette gjennomsnittet, 1=perfekt forklart varians

Trening, validering og test

- Trening: tilpasse modellen
- Validering: velge modell/hyperparametre
- Test: Kun for endelig vurdering. Skal ikke røres før endelig modell er valgt
- Tips: Sammenlign gjerne mot en enkel baseline (f.eks. en enkel modell som bare gjetter gjennomsnittet fra treningsdataene)


Under- og overtilpasning

- Undertilpasning (høy bias): for enkel modell. Klarer ikke fange opp variansen i dataene.
- Overtilpasning (høy varians): tilpasser seg også støyen i dataene. Ofte supergod på trening, men dårlig på testsettet



Gradient descent

- Iterativ metode når lukket f.eks ikke OLS er praktisk mulig
- $\beta \leftarrow \beta - \eta \cdot \nabla L$ (η = læringsrate)
- For liten η : langsom konvergens
- For stor η : divergerer
- SGD: bruker tilfeldige batcher – nødvendig for store data og nevrale nett




Regresjon som statistisk modell

- To skoler: den tradisjonelle - forklare vs. den nye – predikere
- statsmodels: koeffisienter med standardfeil, t-test, 95 % KI


Regularisering: Ridge og Lasso

- Straffer store koeffisienter $\rightarrow$ reduserer overtilpasning
- Lasso kan sette koeffisienter til nøyaktig 0 $\rightarrow$ variabelseleksjon



Kryssvalidering og datalekkasje


- K-fold: del treningsdata i K deler, roter hvilken som validerer
- All læring fra data (skalering, imputering, feature-seleksjon) Må inn i en Pipeline og skal ikke gjøres på dataene før splitting i trening/val/test eller CV
- Riktig: seleksjon kun på treningsfoldene, inne i pipelinen




Hyperparametersøk

- GridSearchCV: systematisk søk over et parameterrom
- Kombiner med kryssvalidering for hver kombinasjon
- Endelig vurdering skjer alltid på testsettet

Oversikt over grid search «pipeline»





Fullstendig regresjonsprosjekt


- ColumnTransformer:
 - Kontinuerlige data $\rightarrow$ imputer + skaler,
 - kategorisk $\rightarrow$ one-hot
- Sammenlign flere modeller med repetert kryssvalidering
- Er beste modell signifikant bedre? Korrigert t-test (fra i går)

Del 2:


Klassifisering

Fra lineær til logistisk regresjon


- Lineær regresjon kan gi verdier utenfor $[0, 1]$
- Sigmoid «skviser» inn prediksjonen: $\sigma(z) = 1 / (1 + e^{-z})$ inn mellom 0 og 1
- $z = \beta_0 + \beta_1 x_1 + \dots$ (samme lineære kombinasjon som før)



Logistisk regresjon




Lineær regresjon



Logistisk regresjon

Logistisk regresjon på binært utfall

- Eksempel: timer studert $\rightarrow$ bestått eksamen (ja/nei)



Forvirringsmatrise og metrikker

Metrikk	Formel	Spørsmål den svarer på
Nøyaktighet	$(TP+TN)/(TP+TN+FP+FN)$	Hvor mange riktige totalt?
Sensitivitet	$TP/(TP+FN)$	Hvor mange positive fant vi?
Spesifisitet	$TN/(TN+FP)$	Hvor mange negative fant vi?
Presisjon	$TP/(TP+FP)$	Hvor mange positive var riktige?
F1-score	$2 \cdot (P \cdot S)/(P+S)$	Balanse presisjon/sensitivitet

Forvirringsmatrisen visuelt

- TN og TP: modellen har rett
- FP: falsk alarm
- FN: oversett tilfelle

Faktisk 0	TN 85	FP 8
Faktisk 1	FN 5	TP 40
	Predikert 0	Predikert 1

Prediksjonsterskelen

- Modellen gir en slags sannsynlighet. En prediksjonsterskel avgjør klassen
- For binær klassifisering er utgangspunktet ofte 0.5, men det kan og bør velges basert på domene og problemstilling
- Lavere terskel → høyere sensitivitet, lavere presisjon

Presisjon avhenger av prevalens


- Samme modell (sens=93 %, spes=99 %) i to populasjoner:
- Prevalens 37 %: presisjon = 98 %
- Prevalens 1 %: presisjon = 46 %

Falsk-positiv paradokset

- Sykdom: prevalens 1 %. Test: sensitivitet 90 %, spesifisitet 95 %
- Du tester positivt – hvor sannsynlig er det at du er syk?
- $P(\text{syk} \mid \text{positiv test}) = 15 \% (!)$
- Presisjonen avhenger sterkt av prevalens

Nøyaktighetsfella

- Vi ser for oss et datasett som beskriver kredittkortsvindel
 - 98 % er ikke svindlere
 - 2% svindler
- En modell som alltid gjetter «ikke svindler» får 98 % nøyaktighet, men finner selvsagt ingen svindlere Ved ubalanserte klasser: se på flere metrikker som sensitivitet, presisjon, F1 og ikke nøyaktighet alene




Strategier for ubalanserte data

- Balansere data ved å fjerne data fra klassen med flest eksempler
- Klassevekter (`class_weight="balanced"`) - straff feil på underrepresenterte data hardere
- SMOTE – oppsample underrepresenterte klasser med å legge til syntetiske data som genereres ved interpolering


Receiver operating characteristic (ROC)-kurve

- ROC: sensitivitet vs. 1–spesifisitet, for alle terskler
- Area under the curve (AUC): sannsynlighet for at en tilfeldig positiv rangeres over en tilfeldig negativ
- Presisjon-recall (PR)-kurve: lurt å supplere med ved sterk ubalanse i klassene



Precision-recall-kurve

- Stiplet linje = tilfeldig klassifikator
(= prevalensen)




Velge terskel ut fra krav

- Eksempel: krav om sensitivitet $\geq 90\%$
- Finn terskelen på treningsdata (out-of-fold), tesyt og rapporter på test
- Youdens $J = \text{sensitivitet} + \text{spesifisitet} - 1$ (balansert valg)
- Kostnadsminimering: vekt FN og FP ulikt (f.eks. 20:1)

Kalibrering

- Betyr «70 %» at 70 % av slike tilfeller (de som oppnår denne prediksjonsskåren) faktisk er positive?
- Sjekk med kalibreringskurve før dere bruker sannsynlighetene direkte




K-fold, GridSearch og nested CV

- Repetert stratifisert K-fold for stabile estimer
- Korrigert t-test (Nadeau–Bengio) for å sammenligne modeller
- Nested CV: Indre løkke brukes til å fastsette hyperparametre, ytre løkke evaluerer og gir et ytelsesestimat uten indirekte overtilpassning

Subgrupper og rettferdighet

- Total ytelse kan skjule dårlig ytelse for en undergruppe
- Rapporter sensitivitet/spesifisitet for relevante undergrupper
- Mulige årsaker til forskjell i undergrupper: ulik prevalens, skjev datainnsamling, proxy-variabler, mer subtile mønstre i noen grupper



Takk for i dag!

Neste: Samling 3 – 26 og 27 oktober